

Задача №1

Необходимо загрузить данные из набора Swiss и произвести следующие действия:

1. Оценить среднее значение, дисперсию и СКО переменных *Infant.Mortality*, *Agriculture* и *Examination*.
2. Построить зависимости вида $y = a + bx$, где y – *Infant.Mortality*, x – *Agriculture/Examination*.
3. Оценить, насколько «хороша» модель по коэффициенту детерминации R^2 .
4. Оценить, есть ли взаимосвязь между объясняемой переменной (*Infant Mortality*) и объясняющей переменной (*Agriculture/Examination*).

1. Оценим среднее значение, дисперсию и СКО переменных *Infant.Mortality*, *Agriculture* и *Examination*.

На рисунке 1 представлен результат команд *mean*, *var* и *sd* для переменной *Infant.Mortality*

```
> mean(data$Infant.Mortality)
[1] 19.94255
> var(data$Infant.Mortality)
[1] 8.483802
> sd(data$Infant.Mortality)
[1] 2.912697
```

Рисунок 1. Результат команд *mean*, *var* и *sd* для переменной *Infant.Mortality*

Значения переменной *Infant.Mortality* не сильно отличаются от среднего, то есть СКО и дисперсия не слишком велики.

На рисунке 2 представлен результат команд *mean*, *var* и *sd* для переменной *Agriculture*.

```
> mean(data$Agriculture)
[1] 50.65957
> var(data$Agriculture)
[1] 515.7994
> sd(data$Agriculture)
[1] 22.71122
```

Рисунок 2. Результат команд *mean*, *var* и *sd* для переменной *Agriculture*

Значения переменной *Agriculture* сильно отличаются от среднего, то есть СКО и дисперсия велики.

На рисунке 3 представлен результат команд *mean*, *var* и *sd* для переменной *Examination*.

```
> mean(data$Examination)
[1] 16.48936
> var(data$Examination)
[1] 63.64662
> sd(data$Examination)
[1] 7.977883
```

Рисунок 3. Результат команд *mean*, *var* и *sd* для переменной *Examination*

Значения переменной *Examination* варьируются от среднего, но не так сильно, как во 2 случае, но при этом сильнее, чем в 1 случае.

2-4. Построим модель, где *Infant.Mortality* – объясняемая переменная, *Agriculture* – объясняющая переменная:

```
model1 = lm(Infant.Mortality~Agriculture, data)
```

На рисунке 4 представлен результат команды *summary* для построенной линейной модели.

```
> summary(model1)

Call:
lm(formula = Infant.Mortality ~ Agriculture, data = data)

Residuals:
    Min       1Q   Median       3Q      Max
-9.4193 -1.7598  0.1247  1.7117  6.5376

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 20.337955   1.057543  19.231  <2e-16 ***
Agriculture -0.007805   0.019083  -0.409   0.684
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.939 on 45 degrees of freedom
Multiple R-squared:  0.003704, Adjusted R-squared:  -0.01844
F-statistic: 0.1673 on 1 and 45 DF, p-value: 0.6845
```

Рисунок 4. Результат команды *summary* для модели *Infant.Mortality ~ Agriculture*

Коэффициент детерминации R^2 в этой модели около 0.004, поэтому мы заключаем, что модель плоха - доля необъясненных моделью значений велика.

$p\text{-value} = 0.68$, т.е. значение p -статистики говорит о том, что велика вероятность сильных отличий реального значения коэффициента от рассчитанного.

Построим зависимость вида $y = a + bx$, где y – *Infant.Mortality*, x – *Agriculture*, используя данные из рисунка 4:

$\text{Infant.Mortality} = 20.34 - 0.008 * \text{Agriculture}$ – зависимость отрицательная.

На рисунке 5 представлен график зависимости *Infant.Mortality ~ Agriculture*.




Рисунок 5. График зависимости модели *Infant.Mortality ~ Agriculture*

Таким образом, мы можем сделать вывод, что взаимосвязи между объясняемой переменной *Infant.Mortality* и объясняющей переменной *Agriculture* практически нет.

Теперь построим модель, где *Infant.Mortality* – объясняемая переменная, *Examination* – объясняющая переменная:

`model2 = lm(Infant.Mortality~Examination, data).`

На рисунке 6 представлен результат команды `summary` для построенной линейной модели.

```
> summary(model2)

Call:
lm(formula = Infant.Mortality ~ Examination, data = data)

Residuals:
    Min       1Q   Median       3Q      Max
-8.5385 -1.7380 -0.0046  1.5706  6.3457

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  20.62899    0.98846   20.87  <2e-16 ***
Examination  -0.04163    0.05407   -0.77    0.445
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.926 on 45 degrees of freedom
Multiple R-squared:  0.013,    Adjusted R-squared:  -0.008932
F-statistic: 0.5927 on 1 and 45 DF,  p-value: 0.4454
```

Рисунок 6. Результат команды `summary` для модели *Infant.Mortality ~ Examination*

Коэффициент детерминации R^2 в этой модели около 0.01, поэтому мы заключаем, что модель плоха — доля необъясненных моделью значений велика.

p -value ≈ 0.45 , т.е значение p -статистики говорит о том, что велика вероятность сильных отличий реального значения коэффициента от рассчитанного.

Построим зависимость вида $y = a + bx$, где y – *Infant.Mortality*, x – *Examination*, используя данные из рисунка 6:

Infant.Mortality = 20.63 - 0.042 * *Examination* – зависимость отрицательная.

На рисунке 7 представлен график зависимости *Infant.Mortality ~ Examination*.




Рисунок 7. График зависимости модели *Infant.Mortality ~ Examination*

Таким образом, мы можем сделать вывод, что взаимосвязи между объясняемой переменной *Infant.Mortality* и объясняющей переменной *Examination* практически нет.

Код к задаче №1 в Приложении 1.

Задача №2

Часть 1.

Необходимо загрузить данные из набора attitude и произвести следующие действия:

1. Проверить, что в наборе данных нет линейной зависимости между регрессорами *complaints*, *learning* и *raises* (построить зависимости между переменными и проверить, что R^2 в каждой из них невысокий). В случае, если R^2 большой, один из таких столбцов можно исключить из рассмотрения.
 2. Построить линейную модель зависимой переменной *rating* от регрессоров *complaints*, *learning* и *raises* по методу наименьших квадратов (команда `lm` пакета `lmtest` в языке R). Оценить, насколько хороша модель, согласно: 1) R^2 , 2) p -значениям каждого коэффициента.
 3. Ввести в модель логарифмы регрессоров (если возможно). Сравнить модели и выбрать наилучшую.
 4. Ввести в модель всевозможные произведения пар регрессоров, в том числе квадраты регрессоров. Найдите одну или несколько наилучших моделей по доле объяснённого разброса в данных R^2 .
 5. Выбрать одну из лучших моделей. Перечислить все регрессоры x в ней и построить парные регрессии $y = a + bx$. Если переменная x значима, сделать вывод о наличии взаимосвязи между объясняемой переменной y и рассматриваемой объясняющей переменной x : отрицательной (если коэффициент $b < 0$) или положительной (если коэффициент $b > 0$).
1. Построим парные зависимости между переменными *complaints*, *learning* и *raises*. Сведения об коэффициенте детерминации R^2 в регрессиях и выводе о наличии линейной зависимости представим в таблице 1.

Таблица 1. Коэффициент детерминации и выводы о наличии линейной зависимости между переменными *complaints*, *learning* и *raises*.

Модель	R^2	Наличие линейной зависимости
<i>complaints ~ learning</i>	35,61%	Линейной зависимости нет.
<i>complaints ~ raises</i>	44,78%	Линейной зависимости нет.
<i>learning ~ raises</i>	41%	Линейной зависимости нет.

Значит, линейной зависимости нет и регрессоры можно использовать регрессоры вместе.

2. Построим линейную модель зависимой переменной *rating* от регрессоров *complaints*, *learning* и *raises* по методу наименьших квадратов:
`model1 = lm(rating ~ complaints + learning + raises, data)`

На рисунке 8 представлен результат команды *summary* для построенной линейной модели.

```
Call:
lm(formula = rating ~ complaints + learning + raises, data = data)

Residuals:
    Min       1Q   Median       3Q      Max
-11.6282  -5.8107   0.5115   6.3946  10.3509

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 10.52260    8.30481   1.267   0.216
complaints   0.65349    0.13637   4.792 5.82e-05 ***
learning     0.22069    0.14967   1.475   0.152
raises      -0.02864    0.18245  -0.157   0.876
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 6.943 on 26 degrees of freedom
Multiple R-squared:  0.7083,    Adjusted R-squared:  0.6746
F-statistic: 21.04 on 3 and 26 DF,  p-value: 3.957e-07
```

Рисунок 8. Результат команды *summary* для зависимости $rating \sim complaints + learning + raises$

Коэффициент детерминации $R^2 = 70,83\%$ — выбранный набор регрессоров неплохо описывает динамику переменной *rating*.

Оценим *p*-значения при коэффициентах:

p-value при *complaints*: 5.82e-05 (***) — регрессор является значимым

p-value при *learning*: 0.152; *p-value* велико, регрессор плохо объясняет динамику *rating* (звездочек нет)

p-value при *raises*: 0.876; *p-value* велико, регрессор плохо объясняет динамику *rating* (звездочек нет)

Тогда попробуем проводить исследования без регрессора *raises* (регрессор незначим).

2. Введём в модель логарифмы регрессоров.

В кодах 1, 2 представлены рассмотренные нами модели с логарифмами регрессоров.

```
#Будем вводить в модель логарифмы регрессоров.

model8 = lm(rating ~ complaints + learning + log(complaints) + log(learning) + log(raises), data)
summary(model8)
#R^2 = 73,38%
vif(model8)

model9 = lm(rating ~ complaints + learning + log(complaints) + log(learning), data)
summary(model9)
#R^2 = 73,38%
vif(model9)

model10 = lm(rating ~ complaints + learning + log(complaints) + log(raises), data)
summary(model10)
#R^2 = 70,96%
vif(model10)

model11 = lm(rating ~ complaints + learning + log(learning) + log(raises), data)
summary(model11)
#R^2 = 72,88%
vif(model11)

model12 = lm(rating ~ complaints + learning + log(complaints), data)
summary(model12)
#R^2 = 70,88%
vif(model12)

model13 = lm(rating ~ complaints + learning + log(learning), data)
summary(model13)
#R^2 = 72,83%
vif(model13)

model14 = lm(rating ~ complaints + learning + log(raises), data)
summary(model14)
#R^2 = 70,83%
vif(model14)
```

Код 1. Модели с логарифмами регрессоров

```

model15 = lm(rating ~ complaints + log(learning) + log(raises), data)
summary(model15)
#R^2 = 70,2%
vif(model15)

model16 = lm(rating ~ log(complaints) + log(learning), data)
summary(model16)
#R^2 = 69,64%
vif(model16)

model17 = lm(rating ~ log(complaints) + learning + log(raises), data)
summary(model17)
#R^2 = 70,69%
vif(model17)

model18 = lm(rating ~ complaints + log(learning) + log(raises), data)
summary(model18)
#R^2 = 70,2%
vif(model18)

model19 = lm(rating ~ log(complaints) + log(learning) + log(raises), data)
summary(model19)
#R^2 = 69,81%
vif(model19)

```

Код 2. Модели с логарифмами регрессоров – продолжение

Исходя из значения коэффициента детерминации R^2 , на данный момент лучшей моделью является модель $rating \sim complaints + learning + log(complaints) + log(learning)$ ($R^2 = 73,38\%$). Далее будем работать с ней.

3. Теперь будем вводить в модель произведения пар регрессоров, в том числе квадраты регрессоров. В коде 3 представлены рассмотренные нами модели с произведениями пар регрессоров и квадратами регрессоров.

```

#Будем вводить в модель произведения пар регрессоров и квадраты регрессоров.

model20 = lm(rating ~ complaints + learning + I(complaints*learning), data)
summary(model20)
#R^2 = 71,33%
vif(model20)

model21 = lm(rating ~ complaints + learning + I(complaints*raises), data)
summary(model21)
#R^2 = 70,83%
vif(model21)

model22 = lm(rating ~ complaints + learning + I(learning*raises), data)
summary(model22)
#R^2 = 70,81%
vif(model22)

model23 = lm(rating ~ complaints + learning + I(complaints^2), data)
summary(model23)
#R^2 = 70,89%
vif(model23)

model24 = lm(rating ~ complaints + learning + I(learning^2), data)
summary(model24)
#R^2 = 72,6%

model25 = lm(rating ~ complaints + learning + I(raises^2), data)
summary(model25)
#R^2 = 70,84%

model26 = lm(rating ~ complaints + I(learning^2) + I(raises^2), data)
summary(model26)
#R^2 = 71,36%

model27 = lm(rating ~ I(complaints^2) + learning + I(raises^2), data)
summary(model27)
#R^2 = 69,62

model28 = lm(rating ~ I(complaints^2) + I(learning^2) + I(raises^2), data)
summary(model28)
#R^2 = 70,03%

```

Код 3. Модели с произведениями пар регрессоров и квадратами регрессоров

Снова попробуем добавить логарифмы регрессоров в модель.

В коде 4 представим рассмотренные нами модели с произведениями пар регрессоров, квадратами регрессоров и логарифмами регрессоров.

```
#Попробуем добавить логарифмы.

model29 = lm(rating ~ complaints + learning + log(complaints) + log(learning) + I(raises^2), data)
summary(model29)
#R^2 = 73,42%
vif(model29)

model30 = lm(rating ~ complaints + learning + log(complaints) + I(learning^2) + log(raises), data)
summary(model30)
#R^2 = 72,98%
vif(model30)

model31 = lm(rating ~ complaints + learning + I(complaints^2) + log(learning) + log(raises), data)
summary(model31)
#R^2 = 73,48%
vif(model31)

model32 = lm(rating ~ I(complaints^2) + log(learning) + log(raises), data)
summary(model32)
#R^2 = 69,2%
vif(model32)

model33 = lm(rating ~ log(complaints) + I(learning^2) + log(raises), data)
summary(model33)
#R^2 = 71,35%
vif(model33)

model34 = lm(rating ~ log(complaints) + log(learning) + I(raises^2), data)
summary(model34)
#R^2 = 69,73%
vif(model34)
```

Код 4. Модели с произведениями пар регрессоров, квадратами регрессоров и логарифмами регрессоров

Мы рассмотрели большое количество моделей с логарифмами регрессоров, произведениями пар регрессоров и квадратами регрессоров. Среди них всех, исходя из значения коэффициента детерминации R^2 , лучшей моделью является модель $rating \sim complaints + learning + I(complaints^2) + log(learning) + log(raises)$ ($R^2 = 73,38\%$). Назовём эту модель лучшей и будем работать с ней.

4. В предыдущем пункте лучшей моделью мы назвали модель $rating \sim complaints + learning + I(complaints^2) + log(learning) + log(raises)$, где регрессоры x – $complaints$, $learning$, $I(complaints^2)$, $log(learning)$ и $log(raises)$; y – $rating$. Построим парные регрессии вида $y = a + bx$.

В коде 5 представлены построенные парные регрессии для лучшей модели.

```

pr1 = lm(rating ~ complaints, data)
summary(pr1)
#R^2 = 68.13%
#rating = 0.75*complaints + 14.38
#Выявленная взаимосвязь положительная (т.к коэффициент перед complaints положительный)

pr2= lm(rating ~ learning, data)
summary(pr2)
#R^2 = 38,9%
#rating = 0.64*learning + 28.2
#Выявленная взаимосвязь положительная (т.к коэффициент перед learning положительный)

pr3= lm(rating ~ I(complaints^2), data)
summary(pr3)
#R^2 = 67,2%
#rating = 5.706e-03*I(complaints^2) + 3.835e+01
#Выявленная взаимосвязь положительная (т.к коэффициент перед I(complaints^2) положительный)

pr4= lm(rating ~ log(learning), data)
summary(pr4)
#R^2 = 37,3%
#rating = 34.3*log(learning) - 72.8
#Выявленная взаимосвязь положительная (т.к коэффициент перед learning положительный)

pr5 = lm(rating ~ log(raises), data)
summary(pr5)
#R^2 = 36,44%
#rating = 45.21*log(raises) - 123.26
#Выявленная взаимосвязь положительная (т.к коэффициент перед learning положительный)

```

Код 5. Парные регрессии для лучшей модели

Во всех регрессиях взаимосвязь между объясняемой переменной y и рассматриваемой объясняющей переменной x положительная.

Часть 2.

Для лучшей зависимости, построенной при решении части 1 задачи №2, оценить:

1. Доверительные интервалы для всех коэффициентов в модели, $p = 95\%$.
2. Сделать вывод о отвержении или невозможности отвергнуть статистическую гипотезу о том, что коэффициент равен 0.
3. Доверительный интервал для одного прогноза ($p = 95\%$, набор значений регрессоров – произвольный).
4. Для каждого регрессора x (в первой степени, не его функции), участвующего в модели, построить парную регрессию $y = a + bx$, где y – объясняемая переменная. Для каждой парной зависимости оценить доверительный интервал коэффициента b .

1. Оценим доверительные интервалы для всех коэффициентов в лучшей модели – $rating \sim complaints + learning + I(complaints^2) + log(learning) + log(raises)$. На рисунке 9 продемонстрирован результат команды `summary` для лучшей модели.


```
Call:
lm(formula = rating ~ complaints + learning + I(complaints^2) +
    log(learning) + log(raises), data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-11.6828	-4.7487	0.1699	4.5150	9.6448

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	260.200684	170.169879	1.529	0.139
complaints	1.338499	0.951817	1.406	0.172
learning	1.879457	1.102823	1.704	0.101
I(complaints^2)	-0.005224	0.007075	-0.738	0.467
log(learning)	-90.279058	60.060753	-1.503	0.146
log(raises)	-1.101701	13.199920	-0.083	0.934

Residual standard error: 6.89 on 24 degrees of freedom

Multiple R-squared: 0.7348, Adjusted R-squared: 0.6796

F-statistic: 13.3 on 5 and 24 DF, p-value: 2.878e-06

Рисунок 9. Результат команды summary для лучшей модели

Количество степеней свободы/измерений в обучающей выборке – 30. Рассчитано 6 коэффициентов. Число степеней свободы df в модели: $30 - 6 = 24$. Для такого числа степеней свободы и $p = 95\%$ значение t -критерия Стьюдента: $t = 2.06$. Команда R , которая позволяет получить значение этой статистики:

$t_critical = qt(0.975, df = 24)$

Продemonстрируем вычисленные доверительные интервалы для всех регрессоров в модели в таблице 2.

Таблица 2. Доверительные интервалы для парных зависимостей

Регрессор	Вычисленное в модели значение коэффициента	Стандартная ошибка коэффициента в модели	Доверительный интервал ($p = 95\%$, $df = 30$, $t = 2.06$)	Содержит ли доверительный интервал 0?
Свободный коэффициент	260.2	170.2	[-90.412, 610,812]	0 лежит в этом интервале, гипотезу о том, что коэффициент равен 0, нельзя отвергнуть.
complaints	1.34	0.95	[-0.617, 3.297]	0 лежит в этом интервале, гипотезу о том, что коэффициент равен 0, нельзя отвергнуть.
learning	1.88	1.1	[-0.386, 4.146]	0 лежит в этом интервале, гипотезу о том, что коэффициент

				равен 0, нельзя отвергнуть.
complaints ^ 2	-0.005	0.007	[-0.01942, 0.00942]	0 лежит в этом интервале, гипотезу о том, что коэффициент равен 0, нельзя отвергнуть.
log(learning)	-90.3	60.06	[-214.0236, 33.4236]	0 лежит в этом интервале, гипотезу о том, что коэффициент равен 0, нельзя отвергнуть.
log(raises)	-1.1	13.2	[-28.292, 26.092]	0 лежит в этом интервале, гипотезу о том, что коэффициент равен 0, нельзя отвергнуть.

3. Оценим доверительный интервал для прогноза с произвольным набором регрессоров. Будем работать со следующей моделью: $rating \sim learning + complaints + raises$. На рисунке 10 продемонстрирован доверительный интервал для прогноза.

```
model = lm(rating ~ learning + complaints + raises, data)
new_data = data.frame(learning = 20, complaints = 10, raises = 10)
predict(model, new_data, interval = "confidence")
#      fit      lwr      upr
# 21.18483 6.668517 35.70114
```

Рисунок 10. Доверительный интервал для прогноза

4. Для каждого регрессора x (в первой степени, не его функции), участвующего в лучшей модели, построим парную регрессию $y = a + bx$, где y – объясняемая переменная. Оценим доверительный интервал коэффициента b .

Для любой из парных регрессий справедливо следующее:

Количество степеней свободы/измерений в обучающей выборке – 30. Рассчитано 2 коэффициента. Число степеней свободы df в модели: $30 - 2 = 28$. Для такого числа степеней свободы и $p = 95\%$ значение t -критерия Стьюдента: $t = 2.05$. Команда R , которая позволяет получить значение этой статистики:

$t_critical = qt(0.975, df = 24)$

Продemonстрируем вычисленные доверительные интервалы для всех регрессоров в модели в таблице 3.

Таблица 3. Доверительные интервалы для коэффициента парных регрессий

Зависимость	Вычисленное в модели значение коэффициента	Стандартная ошибка коэффициента в модели	Доверительный интервал ($p = 95\%$, $df = 28$, $t = 2.05$)	Содержит ли доверительный интервал 0?
-------------	--	--	--	---------------------------------------

rating ~ complaints	0.75	0.098	[0.5491, 0.9509]	Доверительный интервал не содержит 0, наиболее вероятное значение коэффициента положительное
rating ~ learning	0.64	0.15	[0.3325, 0.9475]	Доверительный интервал не содержит 0, наиболее вероятное значение коэффициента положительное
rating ~ complaints ^ 2	5.706e-03	7.564e-04	[41.5538e-04, 72.5662e-04]	0 лежит в этом интервале, гипотезу о том, что коэффициент равен 0, нельзя отвергнуть.
rating ~ log(learning)	34.3	8.4	[17.08, 51.52]	Доверительный интервал не содержит 0, наиболее вероятное значение коэффициента положительное
rating ~ log(raises)	45.21	11.28	[22.086, 68.334]	Доверительный интервал не содержит 0, наиболее вероятное значение коэффициента положительное

Подведем итоги проделанной работы.

В первой части задачи мы построили линейную модель $rating \sim complaints + learning + raises$ и, исходя из значения коэффициента детерминации R^2 и p -значениям каждого коэффициента, выяснили, что модель достаточно неплохая. Добавляя различные параметры в модель (логарифмы регрессоров, их произведения и квадраты), мы выявили наилучшую модель по доле объяснённого разброса в данных - $rating \sim complaints + learning + I(complaints^2) + log(learning) + log(raises)$, для которой далее были построены парные регрессии вида $y = a + bx$ (где y – объясняемая переменная, x – объясняющая переменная). Во всех построенных зависимостях была выявлена сильная положительная взаимосвязь между объясняемой и объясняющей переменной.

Во второй части задачи мы рассчитали доверительные интервалы для регрессоров лучшей модели, после чего выяснили, что 0 лежит в интервале для каждого регрессора, что показало

отсутствие взаимосвязи между объясняемой и объясняющей переменной. Исходя из этого, был сделан вывод о невозможности отвергнуть статистическую гипотезу о том, что коэффициент равен 0. Далее, для каждого регрессора, участвующего в модели, мы построили парные регрессии вида $y = a + bx$ (где y – объясняемая переменная, x – объясняющая переменная), оценили доверительный интервал коэффициента b , после чего обнаружили, что во всех регрессиях наблюдается сильная положительная взаимосвязь – оказалось, что в каждой из парных регрессий доверительный интервал коэффициента b не содержит 0 и наиболее вероятное значение коэффициента – положительное.

Код к задаче №2 в приложении 2.

Задача №3

Номер волны выборки РМЭЗ НИУ ВШЭ: 27

Подмножество для пункта 5: городские жители, женщины, не состоявшие в браке; разведенные женщины, с высшим образованием

Необходимо проанализировать данные волны мониторинга экономического положения и здоровья населения РФ (данные обследования РМЭЗ НИУ ВШЭ) и обработать их следующим образом:

- Прочитать данные, выбрать столбцы, необходимые для того, чтобы описать социально-экономическое положение граждан Российской Федерации. Минимальный набор параметров: зарплата, пол, семейное положение, наличие высшего образования, возраст, тип населенного пункта, длительность рабочей недели.
- Из параметра, отвечающего семейному положению, сделать дамми-переменные (с помощью one-hot-encoding): 1) переменная `wed1` имеет значение 1 в случае, если респондент женат, 0 – в противном случае; 2) `wed2=1`, если респондент разведён или вдовец; 3) `wed3 = 1`, если респондент никогда не состоял в браке.
- Из параметра `пол` сделать переменную `sex`, имеющую значение 1 для мужчин и равную 0 для женщин.
- Из параметра, отвечающего типу населённого пункта, создайте одну дамми-переменную `city_status` со значением 1 для города или областного центра, 0 – в противоположном случае.
- Ввести один параметр `higher_educ`, характеризующий наличие полного высшего образования.
- Факторные переменные, «имеющие много значений», такие как: зарплата, длительность рабочей недели и возраст, - необходимо преобразовать в вещественные переменные и нормализовать их: вычесть среднее значение по этой переменной, разделить её значения на стандартное отклонение.

После чего произвести следующие действия:

1. Построить линейную регрессию зарплаты на все параметры, выделенные из данных мониторинга.
2. Поэкспериментировать с функциями вещественных параметров: использовать логарифмы, степени (хотя бы от 0.1 до 2 с шагом 0.1), произведения вещественных регрессоров.
3. Выделить наилучшие модели из построенных: по значимости параметров, включённых в зависимости, и по объяснённой с помощью построенных зависимостей разбросу $\text{adjusted } R^2 - R^2_{adj}$.
4. Для каждого регрессора x (в первой степени, не его функции), участвующего в лучшей модели, построить парную регрессию $y = a + bx$, где y – объясняемая переменная. Указать значимость переменной x , построить доверительный интервал для её коэффициента, указать наличие положительной/отрицательной взаимосвязи между ней и объясняемой переменной.
5. Проверить лучшую модель на заданном подмножестве респондентов. Построить доверительные интервалы для оставшихся в модели коэффициентов и указать, попадает ли 0 в них.

Прочитаем данные волны №27 и обработаем их согласно условию.

Для того, чтобы описать социально-экономическое положение граждан Российской Федерации выберем следующие признаки: зарплата, пол, семейное положение, наличие

высшего образования, возраст, тип населенного пункта, длительность рабочей недели, является ли индивид владельцем\совладельцем предприятия, на котором он работает.

Из параметра, отвечающего семейному положению – *marst*, сделаем *dummy*-переменные, после чего сам параметр удалим из набора данных. В коде 6 представлено *dummy*-кодирование переменной *marst*.

```
#Создадим дамми-переменные из параметра marst:
#1) wed1 = 1 в случае, если респондент женат, 0 – в противном случае;
#2) wed2 = 1, если респондент разведён или вдовец;
#3) wed3 = 1, если респондент никогда не состоял в браке.
data2$wed1 = ifelse(data2$marst == 2, 1, 0)
data2$wed2 = ifelse((data2$marst == 3 | data2$marst == 4) , 1, 0)
data2$wed3 = ifelse(data2$marst == 1, 1, 0)
data2 <- subset(data2, select = -marst)
```

Код 6. *dummy*-кодирование переменной *marst*

Из параметра пол сделаем переменную *sex*, имеющую значение 1 для мужчин и равную 0 для женщин. В коде 7 представлено присвоение переменной *sex* соответствующих значений.

```
#Признаку sex присвоим значение sex = 1 - для мужчин, sex = 0 - для женщин.
data2$sex <- ifelse(data2$sex == 1, 1, 0)
data2$sex
```

Код 7. Присвоение переменной *sex* значений 1 и 0 для мужчин и женщин соответственно

Из параметра, отвечающего типу населённого пункта – *city_status*, создадим одну *dummy*-переменную *city_status* со значением 1 для города или областного центра, со значением 0 – в противоположном случае. В коде 8 представлено *dummy*-кодирование параметра *city_status*.

```
#Создадим дамми-переменную из параметра city_status:
#city_status = 1 для города или областного центра, city_status = 0 – в противоположном случае.
data2$city_status = ifelse((data2$city_status == 1 | data2$city_status == 2),1,0)
```

Код 8. *dummy*-кодирование переменной *city_status*

Введем один параметр *higher_educ*, характеризующий наличие полного высшего образования, после чего сам параметр удалим из набора данных. В коде 9 представлена реализация переменной *higher_educ*

```
#Введём параметр higher_educ, характеризующий наличие полного высшего образования.
#(В демографическом исследовании 6 - это законченное высшее образование и выше)
data2$higher_educ = ifelse(data2$education == 6, 1,0)
data2 <- subset(data2, select = -education)
```

Код 9. Создание переменной *higher_educ*

Факторные переменные, «имеющие много значений», такие как: зарплата, длительность рабочей недели и возраст, преобразуем в вещественные переменные. В коде 10 представлено преобразование факторных переменных в вещественные.

```
data2$age <- as.numeric(data2$age)
data2$working_day <- as.numeric(data2$working_day)
```

Код 10. Преобразование факторных переменных в вещественные

Теперь нормализуем преобразованные переменные. На коде 11 представлена нормализация параметров, отвечающих за зарплату, длительность рабочей недели и возраст.

```
#Нормализация
mean_salary <- mean(data2$salary)
sd_salary <- sd(data2$salary)
data2$salary <- (data2$salary - mean_salary) / sd_salary

mean_age <- mean(data2$age)
sd_age <- sd(data2$age)
data2$age <- (data2$age - mean_age) / sd_age

mean_working_day <- mean(data2$working_day)
sd_working_day <- sd(data2$working_day)
data2$working_day <- (data2$working_day - mean_working_day) / sd_working_day
```

Код 11. Нормализация вещественных параметров

1. Построим линейную регрессию зарплаты на все параметры, выделенные из данных мониторинга:

```
model = lm(salary ~ sex + higher_educ + age + city_status + working_day + owner + wed1 + wed2 + wed3, data2)
```

На рисунках 11 и 12 представлен результат команд `summary` и `vif` для построенной модели соответственно.

```
Call:
lm(formula = salary ~ sex + higher_educ + age + city_status +
    working_day + owner + wed1 + wed2 + wed3, data = data2)

Residuals:
    Min       1Q   Median       3Q      Max
-2.3004 -0.5773 -0.1329  0.4540  3.6032

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.68405    0.65675   2.564 0.01181 *
sex           0.43681    0.14148   3.087 0.002348 **
higher_educ   0.55256    0.14264   3.874 0.000151 ***
age          -0.61208    0.53679  -1.140 0.255732
city_status   0.03938    0.14189   0.277 0.781726
working_day   0.24964    0.53974   0.463 0.644277
owner         1.31462    0.40208   3.270 0.001297 **
wed1          0.36352    0.22862   1.590 0.113621
wed2          0.37834    0.24676   1.533 0.127018
wed3          0.33367    0.26652   1.252 0.212261
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.8812 on 175 degrees of freedom
Multiple R-squared:  0.2614,    Adjusted R-squared:  0.2234
F-statistic: 6.882 on 9 and 175 DF,  p-value: 1.844e-08
```

Рисунок 11. Результат команды `summary` для линейной регрессии $salary \sim sex + higher_educ + age + city_status + working_day + owner + wed1 + wed2 + wed3$

```
> vif(model)
sex higher_educ age city_status working_day owner wed1
1.170299 1.104577 68.271439 1.114980 69.023833 1.969283 3.105386
wed2 wed3
2.413223 2.480026
```

Рисунок 12. Результат команды `vif` для линейной регрессии $salary \sim sex + higher_educ + age + city_status + working_day + owner + wed1 + wed2 + wed3$

В построенной модели скорректированный коэффициент детерминации $R_{adj}^2 = 22,34\%$. Исходя из значения `vif`, параметры `age` и `working_day` коррелируют друг с другом. Тогда попробуем удалить параметр `working_day` из модели (т.к. регрессор является незначимым – *p-value* большое, звездочек нет). Построим следующую модель:

```
model1 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + wed3, data2).
```

На рисунках 13 и 14 представлен результат команд `summary` и `vif` для построенной модели соответственно.

```
Call:
lm(formula = salary ~ sex + higher_educ + age + city_status +
    owner + wed1 + wed2 + wed3, data = data2)

Residuals:
    Min       1Q   Median       3Q      Max
-2.3032 -0.5783 -0.1317  0.4462  3.6057

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.94618    0.33109   5.878 2.04e-08 ***
sex           0.43877    0.14110   3.110 0.002185 **
higher_educ   0.54769    0.14193   3.859 0.000160 ***
age          -0.36797    0.09768  -3.767 0.000225 ***
city_status   0.03696    0.14148   0.261 0.794222
owner         1.33529    0.39870   3.349 0.000992 ***
wed1          0.36192    0.22808   1.587 0.114354
wed2          0.37887    0.24620   1.539 0.125637
wed3          0.33640    0.26586   1.265 0.207421
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.8793 on 176 degrees of freedom
Multiple R-squared:  0.2605,    Adjusted R-squared:  0.2269
F-statistic:  7.75 on 8 and 176 DF,  p-value: 6.927e-09
```

Рисунок 13. Результат команды `summary` для линейной регрессии $salary \sim sex + higher_educ + age + city_status + working_day + owner + wed1 + wed2 + wed3$

```
> vif(model1)
sex higher_educ age city_status owner wed1 wed2 wed3
1.169246 1.098562 2.270806 1.113469 1.944939 3.104671 2.413171 2.478806
```

Рисунок 14. Результат команды `vif` для линейной регрессии $salary \sim sex + higher_educ + age + city_status + working_day + owner + wed1 + wed2 + wed3$

В построенной модели скорректированный коэффициент детерминации $R_{adj}^2 = 22,69\%$. Без параметра `working_day` зависимость между регрессорами стала меньше, а также сама модель стала лучше. Также заметим, что переменные `wed1`, `wed2`, `wed3` коррелируют друг с другом и не сильно значимы (*p-value* велико, звездочек нет) – попробуем избавиться от какого-каких-нибудь параметров из них.

В коде 12 представлены построенные модели вместе с их vif показателем и скорректированным коэффициентом детерминации R_{adj}^2 .

```
model2_1 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed2 + wed3, data2)
summary(model2_1)
vif(model2_1)
#R^2 = 22.03%
#sex      higher_educ      age city_status      owner      wed2      wed3
#1.070341    1.089778    2.070450    1.109242    1.943499    1.094344    1.178440

model2_2 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed3, data2)
summary(model2_2)
vif(model2_2)
#R^2 = 22.09%
#sex      higher_educ      age city_status      owner      wed1      wed3
#1.128789    1.098474    2.102875    1.112786    1.943232    1.407931    1.440699

model2_3 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2, data2)
summary(model2_3)
vif(model2_3)
#R^2 = 22.43%
#sex      higher_educ      age city_status      owner      wed1      wed2
#1.064077    1.064654    2.118570    1.103794    1.934176    1.475980    1.402551
```

Код 12. Модели без параметров wed1, wed2 и wed3 соответственно

Мы выяснили, что убрав параметр *wed3* (*model2_3*) мы получаем незначительную разницу относительно изначальной модели и наименьшую зависимость между регрессорами. Далее будем работать с этой моделью.

2-3. Поэкспериментируем с функциями вещественных параметров и выделим наилучшую модель из построенных.

Начнем с добавления в модель логарифмов. В коде 13 представлены построенные модели с логарифмами регрессоров.

```
#Логарифмы
model3 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + log(age), data2)
summary(model3)
vif(model3)
#R^2 = 22.23%

model4 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + log(working_day), data2)
summary(model4)
vif(model4)
#R^2 = 22.81%

model5 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + log(age) + log(working_day), data2)
summary(model5)
vif(model5)
#R^2 = 28.83%
#vif у логарифмов большой, но они улучшают модель
```

Код 13. Модели с логарифмами регрессоров

Можем заметить, что, исходя из скорректированного коэффициента детерминации R_{adj}^2 , логарифмы регрессоров немного улучшают модель.

Теперь будем добавлять в модель различные степени регрессоров. В кодах 14-16 представлены построенные модели со степенями регрессоров.

```

#Степени
model6 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^0.1) + I(working_day^0.1), data2)
summary(model6)
vif(model6)
#R^2 = 28.83%

model7 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^0.2) + I(working_day^0.2), data2)
summary(model7)
vif(model7)
#R^2 = 28.82%

model8 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^0.3) + I(working_day^0.3), data2)
summary(model8)
vif(model8)
#R^2 = 28.82%

model9 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^0.4) + I(working_day^0.4), data2)
summary(model9)
vif(model9)
#R^2 = 28.82%

model10 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^0.5) + I(working_day^0.5), data2)
summary(model10)
vif(model10)
#R^2 = 28.81%

model11 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^0.9) + I(working_day^0.9), data2)
summary(model11)
vif(model11)
#R^2 = 28.78%

model12 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^1.1) + I(working_day^1.1), data2)
summary(model12)
vif(model12)
#R^2 = 28.75%

model13 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^1.3) + I(working_day^1.3), data2)
summary(model13)
vif(model13)
#R^2 = 28.7%

```

Код 14. Модели со степенями регрессоров

```

model14 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^1.5) + I(working_day^1.5), data2)
summary(model14)
vif(model14)
#R^2 = 28.64%

model15 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^1.7) + I(working_day^1.7), data2)
summary(model15)
vif(model15)
#R^2 = 28.54%

model16 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^2) + I(working_day^2), data2)
summary(model16)
vif(model16)
#R^2 = 28.31%

model17 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^0.1) + I(working_day^2), data2)
summary(model17)
vif(model17)
#R^2 = 28.51%

model18 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^2) + I(working_day^0.1), data2)
summary(model18)
vif(model18)
#R^2 = 28.78%

model19 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^1.8) + I(working_day^0.3), data2)
summary(model19)
vif(model19)
#R^2 = 28.78%

model20 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^1.6) + I(working_day^0.5), data2)
summary(model20)
vif(model20)
#R^2 = 28.78%

model21 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^1.4) + I(working_day^0.7), data2)
summary(model21)
vif(model21)
#R^2 = 28.77%

```

Код 15. Модели со степенями регрессоров — продолжение

```

model22 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^1.2) + I(working_day^0.9), data2)
summary(model22)
vif(model22)
#R^2 = 28.76%

model23 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^1) + I(working_day^1.1), data2)
summary(model23)
vif(model23)
#R^2 = 22.06%

model24 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^0.8) + I(working_day^1.3), data2)
summary(model24)
vif(model24)
#R^2 = 28.73%

model25 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^0.6) + I(working_day^1.5), data2)
summary(model25)
vif(model25)
#R^2 = 28.69%

model26 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^0.4) + I(working_day^1.7), data2)
summary(model26)
vif(model26)
#R^2 = 28.62%

model27 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^0.2) + I(working_day^1.9), data2)
summary(model27)
vif(model27)
#R^2 = 28.5%

model28 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^0.1) + I(working_day^2), data2)
summary(model28)
vif(model28)
#R^2 = 28.41%

```

Код 16. Модели со степенями регрессоров – продолжение

Мы перебрали большое количество моделей с различными степенями вещественных параметров. На данный момент лучшей из них назовем модель *model6* (исходя из R_{adj}^2 , $R_{adj}^2 = 28.83\%$). Попробуем добавить в эту модель логарифм вещественных параметров. В коде 17 представлена построенная модели с логарифмом вещественных параметров.

```

model32 = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^0.8) + I(working_day^1.3) + I(age*working_day), data2)
summary(model32)
vif(model32)
#R^2 = 28.32%

```

Код 17. Модели с логарифмом вещественных регрессоров

Таким образом, $model6 = salary \sim sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^0.1) + I(working_day^0.1)$ осталась лучшей ($R_{adj}^2 = 28.83\%$); неплохая p -статистика, много звездочек, большая часть регрессоров - значимые. Назовём эту модель лучшей и далее будем работать с ней.

4. Для каждого регрессора x , участвующего в лучшей модели, построим парную регрессию $y = a + bx$, где y – объясняемая переменная, а также построим доверительные интервалы для коэффициента b .

Лучшая модель из пункта 3: $salary \sim sex + higher_educ + age + city_status + owner + wed1 + wed2 + I(age^0.1) + I(working_day^0.1)$. На рисунке 15 представлен результат команды `summary` для модели.

```
Call:
lm(formula = salary ~ sex + higher_educ + age + city_status +
    owner + wed1 + wed2 + I(age^0.1) + I(working_day^0.1), data = data2)

Residuals:
    Min       1Q   Median       3Q      Max
-2.1471 -0.4645 -0.0855  0.4040  3.5192

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   171.07780    54.67481   3.129  0.002055 **
sex             0.37609     0.13204   2.848  0.004923 **
higher_educ     0.67276     0.13606   4.945  1.78e-06 ***
age             5.39838     1.66385   3.245  0.001409 **
city_status     0.05263     0.13525   0.389  0.697617
owner           1.39046     0.38411   3.620  0.000386 ***
wed1            0.19085     0.15125   1.262  0.208680
wed2            0.14521     0.18028   0.805  0.421629
I(age^0.1)     -362.05729    90.10701  -4.018  8.70e-05 ***
I(working_day^0.1) 184.87568    44.42429   4.162  4.95e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.8436 on 175 degrees of freedom
Multiple R-squared:  0.3231,    Adjusted R-squared:  0.2883
F-statistic: 9.28 on 9 and 175 DF, p-value: 1.826e-11
```

Рисунок 15. Результат команды *summary* для лучшей модели

Построим парные регрессии для модели, используя данные из рисунка 15. В кодах 18, 19 представлены построенные зависимости, а также доверительные интервалы для коэффициентов.

```
m1 = lm(salary ~ sex, data2)
summary(m1)
confint(m1, level = 0.95)
#salary = 0.52 * sex + 1.77; *** - регрессор значим; взаимосвязь положительная.
#Доверительный интервал: (0.2377892, 0.8049572).
#Доверительный интервал не содержит 0, наиболее вероятное значение коэффициента положительное.

m2 = lm(salary ~ higher_educ, data2)
summary(m2)
confint(m2, level = 0.95)
#salary = 0.07 * higher_educ + 0.97; *** - регрессор значим; взаимосвязь положительная.
#Доверительный интервал: (0.269732, 0.8565448).
#Доверительный интервал не содержит 0, наиболее вероятное значение коэффициента положительное.

m3 = lm(salary ~ age, data2)
summary(m3)
confint(m3, level = 0.95)
#salary = 0.08 * sex + 0.96; *** - регрессор значим; взаимосвязь положительная.
#Доверительный интервал: (-0.4176475, -0.1374076).
#Доверительный интервал не содержит 0, наиболее вероятное значение коэффициента отрицательное.

m4 = lm(salary ~ city_status, data2)
summary(m4)
confint(m4, level = 0.95)
#salary = 0.23 * city_status + 1.86; регрессор не значим.
#Доверительный интервал: (-0.07276566, 0.5269539).
#Доверительный интервал содержит 0.

m5 = lm(salary ~ owner, data2)
summary(m5)
confint(m5, level = 0.95)
#salary = 0.0004 * owner + 2; регрессор не значим.
#Доверительный интервал: (-0.7318398, 0.5544002).
#Доверительный интервал содержит 0.
```

Код 18. Построенные парные регрессии и доверительные интервалы коэффициента *b* для лучшей модели

```

m6 = lm(salary ~ wed1, data2)
summary(m6)
confint(m6, level = 0.95)
#salary = 0.19 * sex + 0.998; регрессор не значим.
#Доверительный интервал: (-0.09718947 0.4825998).
#Доверительный интервал содержит 0.

m7 = lm(salary ~ wed2, data2)
summary(m7)
confint(m7, level = 0.95)
#salary = 0.02 * sex + 1.995; регрессор не значим.
#Доверительный интервал: (-0.3325647, 0.3806155).
#Доверительный интервал содержит 0.

m8 = lm(salary ~ I(age^0.1), data2)
summary(m8)
confint(m8, level = 0.95)
#salary = -10.237 * sex + 12.9; *** - регрессор значим; взаимосвязь отрицательная.
#Доверительный интервал: (-15.376129 -5.097288).
#Доверительный интервал не содержит 0, наиболее вероятное значение коэффициента отрицательное.

m9 = lm(salary ~ I(working_day^0.1), data2)
summary(m9)
confint(m9, level = 0.95)
#salary = -11.871 * sex + 15.2; *** - регрессор значим; взаимосвязь отрицательная.
#Доверительный интервал: (-18.236880, -5.505343).
#Доверительный интервал не содержит 0, наиболее вероятное значение коэффициента отрицательное.

```

Код 19. Построенные парные регрессии и доверительные интервалы коэффициента b для лучшей модели – продолжение

5. Проверим лучшую модель на следующих подмножествах: городские жители, женщины, не состоявшие в браке; разведенные женщины, с высшим образованием. А также построим доверительные интервалы для оставшихся в модели коэффициентов. В коде 20 продемонстрированы заданные подмножества.

```

#Зададим подмножества:
subset1 <- data2[data2$city_status == 1 & data2$sex == 0 & data2$wed3 == 1, ]
subset2 <- data2[data2$higher_educ == 1 & data2$sex == 0 & data2$wed2 == 1, ]

#Добавим в подмножества недостающие параметры (функции вещественных параметров)
subset1$working_day_deg = I(subset1$working_day^0.1)
subset1$age_deg = I(subset1$age^0.1)

subset2$working_day_deg = I(subset2$working_day^0.1)
subset2$age_deg = I(subset2$age^0.1)

```

Код 20. Заданные подмножества

Теперь построим доверительные интервалы для оставшихся коэффициентов в модели. В коде 21 представлены соответствующие доверительные интервалы.

```

# Проверим доверительные интервалы для оставшихся в модели коэффициентов.
s1model = lm(salary ~ sex + higher_educ + age + city_status + owner + wed1 + wed2 + age_deg + working_day_deg, subset1)
summary(s1model)
confint(s1model, level = 0.95)
#для higher_educ: (-1.118681, 1.694868) - содержит 0
#для age: (-240.064324, 635.707448) - содержит 0
#для owner: (-2.429928, 2.268492) - содержит 0
#для working_day_deg: (-126.640226, 480.021189) - содержит 0

s2model = lm(salary ~ sex + higher_educ + city_status + owner + wed1 + wed2 + age_deg + working_day_deg, subset2)
summary(s2model)
confint(s2model, level = 0.95)

#для city_status: (-3.763845, 3.556905) - содержит 0
#для age_deg: (-75993.608061, 30537.331851) - содержит 0
#для working_day_deg: (-2541.442377, 5577.086902) - содержит 0

```

Код 21. Доверительные интервалы для коэффициентов в модели

Мы выяснили, что во все доверительные интервалы для оставшихся в модели коэффициентов попадает 0.

Таким образом, анализ данных показывает, что зарплата индивида зависит от его пола, возраста, наличия высшего образования и продолжительности рабочего дня. Полученные результаты могут быть связаны не только с этими факторами, однако для более точного вывода и интерпретации данных, необходимо провести дополнительный анализ.

Код к задаче №3 в Приложении 3.